گزارش پروژه‌ی یادگیری عمیق

طبقه‌بندی خودروهای ترافیکی

پیاده‌سازی و ارزیابی مدل‌های یادگیری عمیق برای تشخیص کلاس خودرو از روی تصویر

تهیه‌کننده: مهدی رستم‌زاده

مدل منتخب مرحله‌ی آزمایش: ResNet18

نسخه‌ی گزارش: ۱۴۰۵

این گزارش بر اساس آزمایش‌های ثبت‌شده‌ی پروژه تهیه شده است. نتایجی که هنوز روی مجموعه‌ی آزمون نهایی منتور تأیید نشده‌اند، به‌صورت صریح مشخص شده‌اند.

چکیده

هدف این پروژه، ساخت یک سامانه‌ی طبقه‌بندی تصویر است که بتواند با دریافت تصویر یک وسیله‌ی نقلیه، کلاس آن را از میان هشت گروه تعیین‌شده پیش‌بینی کند. مسیر کار شامل بررسی و پاک‌سازی داده‌ها، آماده‌سازی مجموعه‌ی آموزش، پیاده‌سازی یک شبکه‌ی پایه، بررسی چند ایده‌ی آموزشی و در نهایت آموزش مدل انتقال یادگیری ResNet18 بوده است.

در نسخه‌ی ثبت‌شده‌ی آزمایش اصلی، ۳۹۱۹ تصویر برای آموزش و ۴۰۰ تصویر برای ارزیابی محلی استفاده شده است. مدل ResNet18 پس از ۱۰ Epoch به دقت آموزش ۹۸٫۵۷٪ و دقت ارزیابی محلی ۹۵٫۷۵٪ رسیده است. مقدارهای Macro Precision، Macro Recall و Macro F1 نیز برابر با ۰٫۹۶ گزارش شده‌اند. از آن‌جا که مجموعه‌ی ۴۰۰ تصویری در گردش کار پروژه نقش دارد و مجموعه‌ی نهایی جداگانه‌ای از طرف منتور ارائه شده، این اعداد نباید به‌عنوان نتیجه‌ی آزمون نهایی مستقل معرفی شوند.

تحلیل خطاها نشان می‌دهد تمایز میان کلاس‌های kamyun، kamyunet و minibus از بخش‌های دشوارتر مسئله است. همچنین در گزارش، آزمایش‌های پایه، Dropout و مقایسه‌ی اولیه‌ی تابع زیان ثبت می‌شوند؛ هر آزمایش فقط در حد داده‌های واقعی موجود تفسیر شده است.

راهنمای بخش‌های گزارش

بخش	محتوا
۱	تعریف مسئله و هدف پروژه
۲	ساختار داده‌ها و فرایند ادغام
۳	کنترل کیفیت، تکراری‌ها و ریسک نشت داده
۴	پیش‌پردازش و آماده‌سازی ورودی
۵	مبانی انتقال یادگیری
۶	آزمایش پایه
۷	آزمایش کنترل بیش‌برازش
۸	آزمایش‌های تکمیلی
۹	آموزش ResNet18 و نتایج
۱۰	تحلیل معیارها
۱۱	ماتریس درهم‌ریختگی و تحلیل خطاها
۱۲–۱۵	بررسی مجموعه‌های منتور، بازتولیدپذیری، محدودیت‌ها و کارهای آینده

۱. تعریف مسئله و هدف پروژه

مسئله‌ی پروژه از نوع Image Classification است. هر تصویر به یک کلاس مشخص تعلق دارد و مدل باید با استفاده از نمونه‌های برچسب‌خورده، الگوهای تصویری هر گروه را یاد بگیرد. در زمان پیش‌بینی، شبکه برای تصویر جدید امتیاز یا احتمال هر کلاس را محاسبه کرده و کلاسی را که بالاترین امتیاز را دارد برمی‌گرداند.

۱.۱ کلاس‌های هدف

نام کلاس در کد	توضیح کوتاه
ambulance	آمبولانس
autobus	اتوبوس
kamyun	کامیون
kamyunet	کامیونت
minibus	مینی‌بوس
savari	خودروی سواری
taxi	تاکسی
vanet	وانت

۱.۲ خروجی مورد انتظار

ورودی سامانه یک فایل تصویر است. خروجی مدل باید شامل نام کلاس پیش‌بینی‌شده و در صورت پیاده‌سازی مرحله‌ی استنتاج، امتیاز اطمینان مربوط به کلاس‌ها باشد. در نسخه‌ی فعلی، تمرکز اصلی بر طبقه‌بندی تک‌تصویری است؛ تشخیص محل خودرو در تصویر یا Detection جزو هدف اصلی این نسخه نیست.

۱.۳ چالش اصلی

برخی کلاس‌ها از نظر شکل بدنه، زاویه‌ی تصویربرداری، اندازه‌ی خودرو در تصویر و پس‌زمینه شباهت زیادی دارند. به همین دلیل، دقت کلی به‌تنهایی برای بررسی کیفیت مدل کافی نیست و باید معیارهای هر کلاس، ماتریس درهم‌ریختگی و نمونه‌های اشتباه نیز بررسی شوند.

۲. ساختار داده‌ها و آماده‌سازی مجموعه

در شروع کار، داده‌ها در دو مجموعه‌ی قدیمی و جدید نگهداری می‌شدند و در کنار پوشه‌های آموزش و آزمون، پوشه‌هایی با نام‌های دیگر نیز وجود داشت. طبق تصمیم پروژه، داده‌های قابل‌استفاده‌ی مجموعه‌های قدیمی و جدید پس از بررسی ادغام شدند تا یک مجموعه‌ی آموزش بزرگ‌تر تشکیل شود. پوشه‌ی آزمونِ اضافه به‌صورت خودکار معادل داده‌ی آموزش در نظر گرفته نشد؛ ابتدا باید تصاویر آن بررسی می‌شد و سپس در صورت قابل‌قبول بودن، به مجموعه‌ی آموزش منتقل می‌شد.

منبع	تعداد ثبت‌شده	نکته
منبع ۱	۳۹۷ تصویر	شامل چند کلاس با حدود ۵۰ تصویر
منبع ۲	۴۰۰ تصویر	در گردش کار فعلی به‌عنوان ارزیابی محلی استفاده شد
منبع ۳	۴۵۰ تصویر	نیازمند بررسی کیفیت و برچسب
منبع ۴	۱۵۱۸ تصویر	مجموعه‌ی آموزشی جدید
منبع ۵	۱۵۷۸ تصویر	با منابع دیگر اشتباه گرفته نشود
خروجی ادغام	**۳۹۱۹ تصویر**	مجموعه‌ی آموزش
ارزیابی محلی	۴۰۰ تصویر	نتیجه‌ی ثبت‌شده‌ی مرحله‌ی فعلی

۲.۱ چرا ادغام داده‌ها انجام شد؟

افزایش تعداد نمونه‌های آموزشی می‌تواند به مدل کمک کند تنوع بیشتری از ظاهر خودروها را ببیند. با این حال، ادغام صرفاً بر اساس تعداد تصاویر کافی نیست؛ تصاویر تکراری، برچسب‌های ناسازگار و تفاوت‌های ناخواسته‌ی منبع باید بررسی شوند. در این پروژه، هدف نهایی ساخت یک مجموعه‌ی آموزش واحد و نگه‌داشتن یک مجموعه‌ی ارزیابی محلی مجزا بود.

۲.۲ وضعیت مجموعه‌ی ارزیابی

> **مهم:** مجموعه‌ی ۴۰۰ تصویریِ فعلی برای ارزیابی محلی استفاده شده است. مجموعه‌ی آزمونی که منتور ارائه می‌کند باید جداگانه و پس از تثبیت مدل ارزیابی شود.

۳. کنترل کیفیت و پاک‌سازی داده‌ها

پیش از آموزش، تصاویر از نظر خوانایی فایل، اندازه‌ی تصویر، تکراری بودن و سازگاری برچسب‌ها بررسی شدند. کنترل کیفیت داده اهمیت زیادی دارد؛ زیرا ممکن است مدل به‌جای یادگیری ویژگی‌های واقعی خودرو، از تصاویر تکراری یا نشانه‌های ناخواسته‌ی موجود در عکس استفاده کند.

۳.۱ بررسی فایل‌های نامعتبر

در بررسی ثبت‌شده، تصویر خراب یا تصویر بسیار کوچکِ قابل‌گزارش پیدا نشد. این نتیجه به معنی بی‌نقص بودن همه‌ی برچسب‌ها نیست؛ اعتبار فایل و صحت برچسب دو موضوع جداگانه‌اند.

۳.۲ حذف تصاویر تکراری

در بررسی اولیه، تکراری‌هایی میان داده‌های آموزش و ارزیابی و همچنین میان آموزش و آزمون شناسایی شدند. این تصاویر می‌توانند باعث شوند نمونه‌ای که در آموزش دیده شده، در ارزیابی نیز ظاهر شود و دقت بیش از حد واقعی به نظر برسد. در ادامه‌ی پاک‌سازی، تعدادی از تکراری‌ها حذف شدند.

۳.۳ اختلاف برچسب و هم‌پوشانی محتوا

در ممیزیِ جداگانه‌ی پوشه‌های آزمون منتور، ۶۴۷۲ رخداد تصویر در پوشه‌ها ثبت شده بود، اما هش فایل‌ها نشان داد تنها ۱۱۱۸ محتوای تصویریِ یکتا وجود دارد و برای ۲۶۴ تصویر یکتا، برچسب‌های ناسازگار در کلاس‌های مختلف دیده شده است. بنابراین نتایج اولیه‌ی این پوشه‌ها باید موقت تلقی شوند و پیش از اعلام نتیجه‌ی نهایی، ساختار پوشه‌ها، برچسب‌ها و هم‌پوشانی محتوا اصلاح یا روشن شود.

۳.۴ نشانه‌های ناخواسته در تصویر

در نمونه‌های بررسی‌شده در گزارش مرجع، کادرهای رنگی یا نشانه‌های ثابت روی تصویر می‌توانند به‌عنوان میانبر توسط مدل یاد گرفته شوند. برای پروژه‌ی حاضر نیز باید بررسی شود که مدل واقعاً به بدنه و ویژگی‌های خودرو توجه می‌کند، نه به کادر، واترمارک، پس‌زمینه یا الگوی ثابت عکس‌برداری. این مورد یک ریسک تحلیلی است و تا زمانی که آزمایش جداگانه انجام نشود، نباید ادعا کرد اثر آن به‌طور قطعی اندازه‌گیری شده است.

۴. پیش‌پردازش و آماده‌سازی ورودی

شبکه‌های عصبی تصاویر را به‌صورت آرایه‌های عددی دریافت می‌کنند. بنابراین تصاویر باید به ابعاد و قالب مورد انتظار مدل تبدیل شوند و مقادیر پیکسل‌ها به شکلی سازگار با فرایند آموزش درآیند. در انتقال یادگیری، پیش‌پردازش ورودی باید با روش مورد انتظار وزن‌های پیش‌آموزش‌دیده هماهنگ باشد.

۴.۱ مراحل کلی

1. خواندن تصویر از مسیر فایل و تبدیل آن به قالب تصویری استاندارد.
2. تغییر اندازه‌ی تصاویر برای تشکیل Batchهای هم‌اندازه.
3. تبدیل تصویر به Tensor برای استفاده در شبکه.
4. اعمال Normalization سازگار با وزن‌های ResNet18 در صورت استفاده از تنظیمات استاندارد.
5. استفاده‌ی محتاطانه از Data Augmentation فقط روی داده‌ی آموزش؛ ارزیابی باید تا حد امکان ثابت و قابل مقایسه بماند.

Data Augmentation ۴.۲

افزایش داده با تغییرات کنترل‌شده، مانند برش تصادفی، چرخش محدود یا تغییرات روشنایی، می‌تواند به مدل کمک کند نسبت به تغییرات طبیعی تصاویر مقاوم‌تر شود. با این حال، تبدیل‌ها نباید ماهیت کلاس را تغییر دهند؛ برای نمونه، برش بیش از حد ممکن است بخش تعیین‌کننده‌ی خودرو را حذف کند. هر نوع Augmentation باید با یک آزمایش قابل تکرار و معیار مشخص ارزیابی شود.

۴.۳ جلوگیری از نشت داده

اگر تصاویر یکسان یا بسیار مشابه در Train و Validation قرار بگیرند، ارزیابی قابل اعتماد نخواهد بود. در پروژه‌های تصویری، ممکن است محتوای تکراری با نام فایل متفاوت پنهان شود؛ استفاده از هش محتوا و بررسی نمونه‌های مشابه می‌تواند این ریسک را کاهش دهد. مجموعه‌ی Test باید از داده‌ی آموزش مستقل بماند.

۵. مبانی مدل‌های مورد استفاده

۵.۱ شبکه‌ی عصبی کانولوشنی

شبکه‌ی عصبی کانولوشنی (CNN) از فیلترهای قابل یادگیری برای استخراج الگوهای محلی تصویر استفاده می‌کند. لایه‌های ابتدایی معمولاً الگوهایی مانند لبه و بافت را یاد می‌گیرند و لایه‌های عمیق‌تر ترکیب پیچیده‌تری از ویژگی‌ها را تشخیص می‌دهند. در پایان، لایه‌های طبقه‌بندی از ویژگی‌های استخراج‌شده برای انتخاب یکی از هشت کلاس استفاده می‌کنند.

۵.۲ چرا یک مدل پایه ساخته شد؟

پیاده‌سازی یک مدل ساده کمک می‌کند عملکرد یک شبکه‌ی ساخته‌شده از ابتدا با مدل انتقال یادگیری مقایسه شود. این مقایسه نشان می‌دهد آیا استفاده از ویژگی‌هایی که روی یک مجموعه‌داده‌ی بزرگ‌تر آموخته شده‌اند، برای دیتاست محدود پروژه سودمند است یا خیر.

۵.۳ ResNet18 و انتقال یادگیری

ResNet18 یک معماری کانولوشنی دارای اتصالات میان‌بُر (Skip Connections) است. این اتصالات مسیر مستقیم‌تری برای عبور اطلاعات فراهم می‌کنند و آموزش شبکه‌های عمیق را آسان‌تر می‌سازند. در انتقال یادگیری، از وزن‌های پیش‌آموزش‌دیده استفاده می‌شود و لایه‌ی نهایی متناسب با تعداد کلاس‌های مسئله تغییر می‌کند.

رابطه‌ی مفهومی بلوک باقیمانده: $y = F(x) + x$

در پیاده‌سازی پروژه، مدل ResNet18 با لایه‌ی خروجی متناسب با ۸ کلاس استفاده شده است. فایل وزن آموزش‌دیده‌ی ثبت‌شده نگهداری می‌شود.

۵.۴ تابع زیان و بهینه‌ساز

در طبقه‌بندی چندکلاسه، Cross-Entropy یکی از گزینه‌های متداول است. این تابع اختلاف میان امتیازهای خروجی مدل و برچسب واقعی را اندازه‌گیری می‌کند. بهینه‌ساز نیز با استفاده از برآوردهای تطبیقی گرادیان، پارامترهای مدل را به‌روزرسانی می‌کند. مقدار Learning Rate اندازه‌ی گام به‌روزرسانی را کنترل می‌کند و انتخاب نامناسب آن می‌تواند یادگیری را کند یا ناپایدار کند.

۶. آزمایش اول: مدل پایه

در آزمایش پایه، یک شبکه‌ی CNN سفارشی با چند بلوک کانولوشنی، تابع فعال‌ساز و لایه‌های طبقه‌بندی آموزش داده شد. هدف این آزمایش ایجاد خط مبنا برای مقایسه با ResNet18 بود.

پارامتر	مقدار ثبت‌شده
نوع مدل	CNN سفارشی
تعداد Epoch	۱۰
دقت آموزش	۹۸٫۵۲٪
دقت اعتبارسنجی	۸۲٫۷۵٪
Validation Loss	۱٫۰۱۱

اختلاف محسوس میان دقت آموزش و اعتبارسنجی نشان می‌دهد مدل در داده‌های آموزش عملکرد بسیار خوبی داشته، اما تعمیم آن به تصاویر جداگانه ضعیف‌تر بوده است. این الگو می‌تواند با بیش‌برازش سازگار باشد؛ با این حال، برای تشخیص قطعی علت، باید نمودارهای کامل آموزش و اعتبارسنجی، تنوع داده‌ها و صحت برچسب‌ها نیز بررسی شوند.

۶.۱ تفسیر

- دقت بالای آموزش به‌تنهایی نشان‌دهنده‌ی عملکرد قابل اتکا روی تصاویر جدید نیست.
- استفاده از وزن‌های پیش‌آموزش‌دیده در ResNet18 می‌تواند نقطه‌ی شروع بهتری برای دیتاست نسبتاً کوچک باشد.
- برای مقایسه‌ی منصفانه، مجموعه‌ی ارزیابی، پیش‌پردازش و معیارها باید در تمام آزمایش‌ها یکسان باشند.

نتیجه‌ی این بخش: مدل پایه به‌عنوان خط مبنا ثبت می‌شود، نه به‌عنوان مدل نهایی منتخب.

۷. آزمایش کنترل بیش‌برازش

برای بررسی امکان کاهش بیش‌برازش، یک آزمایش با چند راهکار شامل Augmentation، Dropout و Early Stopping تنظیم شد. هدف این بود که مدل در برابر جزئیات تصادفی داده‌ی آموزش مقاوم‌تر شود.

روش / پارامتر	مقدار ثبت‌شده
Dropout	۰٫۵
حداکثر Epoch	۱۴
Early Stopping	فعال
بهترین دقت اعتبارسنجی	۷۸٫۲۵٪ در Epoch ۸

در این اجرای ثبت‌شده، بهترین دقت اعتبارسنجی ۷۸٫۲۵٪ بوده است که از نتیجه‌ی پایه پایین‌تر است. بنابراین این ترکیب مشخص از تنظیمات بهبود نشان نداده است. این نتیجه به معنی بی‌فایده بودن همه‌ی روش‌ها نیست؛ شدت Dropout، تنظیمات Augmentation و اندازه‌ی داده می‌توانند روی نتیجه اثر بگذارند.

۷.۱ چرا ممکن است نتیجه بدتر شود؟

اگر منظم‌سازی بیش از حد قوی باشد، مدل ممکن است نتواند ویژگی‌های کافی را از داده یاد بگیرد. Augmentation نامتناسب نیز می‌تواند تصاویر آموزش را از توزیع تصاویر اعتبارسنجی دور کند. برای نتیجه‌گیری دقیق، هر عامل باید جداگانه یا در قالب یک طراحی آزمایش کنترل‌شده مقایسه شود.

۸. آزمایش‌های تکمیلی

۸.۱ نمونه‌گیری وزن‌دار

در دیتاست‌های نامتوازن، کلاس‌های پرتعداد ممکن است سهم بیشتری از Batchهای آموزش را تشکیل دهند. نمونه‌گیری وزن‌دار می‌تواند احتمال نمونه‌گیری از کلاس‌های کم‌تعداد را افزایش دهد تا مدل در طول آموزش فرصت بیشتری برای دیدن آن‌ها داشته باشد.

در آزمایش ثبت‌شده، وزن نمونه‌ها بر اساس فراوانی کلاس‌ها تعیین شد و نمونه‌گیری با ۷۲۵ نمونه در هر Epoch انجام گرفت. خروجی این آزمایش نشان داد توزیع نمونه‌های انتخاب‌شده تغییر می‌کند؛ اما به‌تنهایی ثابت نمی‌کند که دقت مدل بهتر شده است. برای ادعای بهبود، مدل باید با و بدون نمونه‌گیری وزن‌دار آموزش داده شود و با معیارهای یکسان مقایسه شوند.

۸.۲ مقایسه‌ی دو تابع زیان

در یک بررسی اولیه روی یک Batch، مقدار زیان برابر ۲٫۰۴۴۶۸ و مقدار زیان در حالت دیگر برابر ۰٫۶۹۴۷۵ ثبت شده است. در این حالت، برچسب‌ها به نمایش One-Hot تبدیل شدند. این اعداد مستقیماً قابل مقایسه نیستند؛ زیرا تعریف و مقیاس دو تابع زیان متفاوت است و ارزیابی تکBatch نیز عملکرد نهایی مدل را نشان نمی‌دهد.

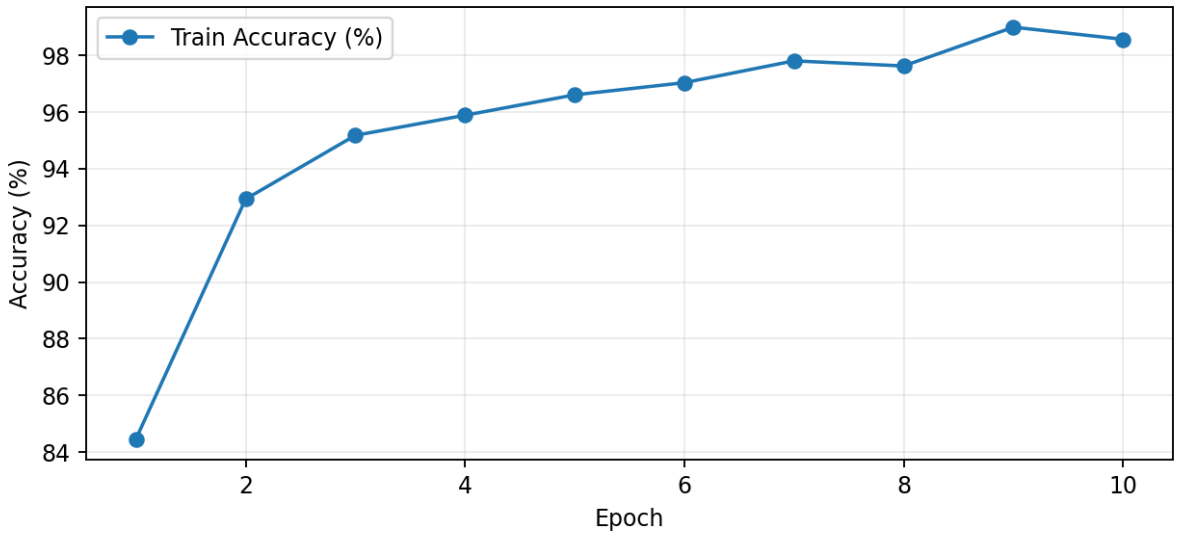
> **نکته‌ی گزارش‌دهی:** مقایسه‌ی بالا در این نسخه، آزمایش مقدماتی است و نباید به‌عنوان اثبات افزایش دقت گزارش شود.

۹. آزمایش اصلی: آموزش ResNet18

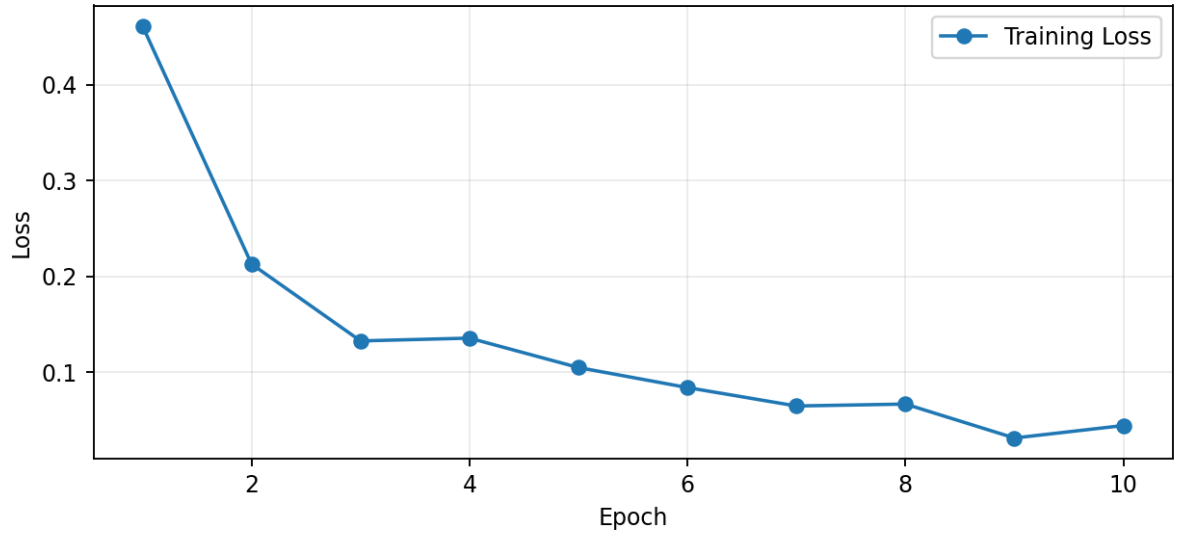
در آزمایش اصلی، ResNet18 با وزن‌های پیش‌آموزش‌دیده استفاده شد و لایه‌ی نهایی برای پیش‌بینی هشت کلاس پروژه تنظیم شد. این مدل به‌عنوان مدل منتخب مرحله‌ی فعلی در نظر گرفته شد؛ زیرا عملکرد ثبت‌شده‌ی آن روی مجموعه‌ی ارزیابی محلی از مدل پایه بهتر بود.

تنظیم	مقدار
مدل	ResNet18
تعداد تصاویر آموزش	۳۹۱۹
تعداد تصاویر ارزیابی محلی	۴۰۰
تعداد Epoch	۱۰
Batch Size	۳۲
Learning Rate	۰٫۰۰۱
دقت آموزش	۹۸٫۵۷٪
دقت ارزیابی محلی	۹۵٫۷۵٪
Macro Precision / Recall / F1	۰٫۹۶ / ۰٫۹۶ / ۰٫۹۶

۹.۱ تاریخچه‌ی آموزش



شکل ۱. روند دقت آموزش در ۱۰ Epoch ثبت‌شده.



شکل ۲. روند Loss آموزش در ۱۰ Epoch ثبت‌شده.

۹.۲ جزئیات به‌تفکیک Epoch

Epoch	Train Loss	Train Accuracy
1	0.4611	84.46٪
2	0.2129	92.93٪
3	0.1327	95.18٪
4	0.1356	95.89٪
5	0.1049	96.61٪
6	0.0840	97.04٪
7	0.0648	97.81٪
8	0.0668	97.63٪
9	0.0314	99.00٪
10	0.0444	98.57٪

در مجموع، دقت آموزش از ۸۴٫۴۶٪ در Epoch اول به ۹۸٫۵۷٪ در Epoch دهم رسیده است. Loss نیز روند کاهشی کلی داشته، هرچند در برخی Epochها نوسان جزئی مشاهده می‌شود. این نوسان در فرایند بهینه‌سازی طبیعی است؛ مهم‌تر از کاهش Loss آموزش، عملکرد مدل روی داده‌ی جداگانه است.

۹.۳ مقایسه با مدل پایه

مدل	دقت آموزش	دقت ارزیابی	برداشت
مدل پایه	۹۸٫۵۲٪	۸۲٫۷۵٪	فاصله‌ی زیاد میان آموزش و اعتبارسنجی
کنترل بیش‌برازش	در گزارش نهایی ثبت نشده	۷۸٫۲۵٪	بهبود اعتبارسنجی مشاهده نشد
ResNet18	**۹۸٫۵۷٪**	**۹۵٫۷۵٪**	بهترین نتیجه‌ی ثبت‌شده در ارزیابی محلی

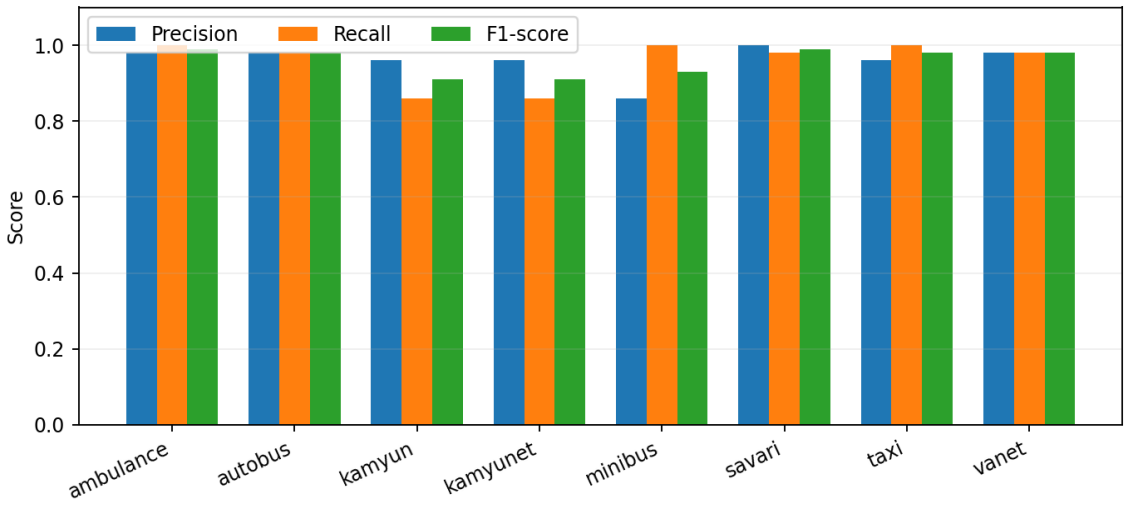
این مقایسه بر اساس اعداد ثبت‌شده است. اگر شرایط دقیق آموزش مدل‌ها یکسان نبوده باشد، اختلاف دقت باید با احتیاط تفسیر شود. با این وجود، در آزمایش‌های فعلی ResNet18 بهترین عملکرد ارزیابی محلی را داشته است.

۱۰. ارزیابی مدل ResNet18

Accuracy سهم پیش‌بینی‌های صحیح از کل نمونه‌ها را نشان می‌دهد. **Precision** نشان می‌دهد از نمونه‌هایی که مدل به یک کلاس نسبت داده، چه سهمی واقعاً متعلق به همان کلاس بوده‌اند. **Recall** سهم نمونه‌های واقعیِ یک کلاس را نشان می‌دهد که درست شناسایی شده‌اند. **F1** میانگین هارمونیک Precision و Recall است و برای مقایسه‌ی متوازن این دو معیار به کار می‌رود.

معیار	مقدار	تفسیر
Accuracy	۹۵٫۷۵٪	۳۸۳ پیش‌بینی صحیح از ۴۰۰ تصویر
Macro Precision	۰٫۹۶	میانگین کلاس‌ها با وزن برابر
Macro Recall	۰٫۹۶	میانگین کلاس‌ها با وزن برابر
Macro F1	۰٫۹۶	میانگین کلاس‌ها با وزن برابر

۱۰.۱ معیارهای هر کلاس



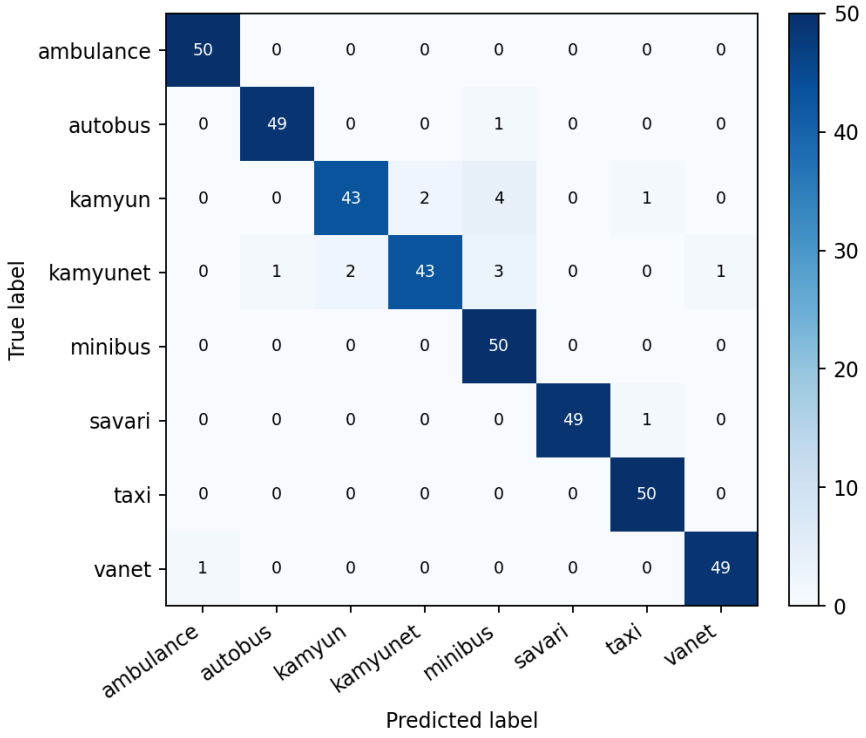
شکل ۳. معیارهای Precision، Recall و F1 برای هر کلاس.

جدول معیارهای هر کلاس

کلاس	Precision	Recall	F1	Support
ambulance	0.98	1.00	0.99	50
autobus	0.98	0.98	0.98	50
kamyun	0.96	0.86	0.91	50
kamyunet	0.96	0.86	0.91	50
minibus	0.86	1.00	0.93	50
savari	1.00	0.98	0.99	50
taxi	0.96	1.00	0.98	50
vanet	0.98	0.98	0.98	50

۱۱. ماتریس درهم‌ریختگی و تحلیل خطا

ماتریس درهم‌ریختگی، تعداد نمونه‌های واقعی هر کلاس را در برابر کلاس پیش‌بینی‌شده نشان می‌دهد. مقادیر روی قطر اصلی پیش‌بینی‌های صحیح هستند و مقادیر خارج از قطر، خطاهای طبقه‌بندی را نمایش می‌دهند.



شکل ۴. ماتریس درهم‌ریختگی آزمایش ResNet18 روی مجموعه‌ی ۴۰۰ تصویری ارزیابی محلی.

۱۱.۱ مهم‌ترین خطاها

- kamyun: از ۵۰ تصویر، تعداد ۴۳ تصویر درست تشخیص داده شد؛ ۲ مورد به kamyunet، ۴ مورد به minibus و ۱ مورد به taxi نسبت داده شد.
- kamyunet: از ۵۰ تصویر، تعداد ۴۳ تصویر درست تشخیص داده شد؛ اشتباه‌ها میان autobus، kamyun، minibus و vanet پراکنده بودند.
- minibus: هر ۵۰ تصویر در این ماتریس درست تشخیص داده شده‌اند؛ با این حال Precision این کلاس برابر ۰٫۸۶ است، زیرا برخی تصاویر کلاس‌های دیگر به‌اشتباه minibus پیش‌بینی شده‌اند.
- کلاس‌های ambulance، minibus و taxi در این مجموعه Recall برابر ۱٫۰۰ دارند؛ یعنی در این ۵۰ نمونه‌ی واقعی برای هر کلاس، موردی از دست نرفته است.

مهم‌ترین ابهام مشاهده‌شده مربوط به شباهت بصری بین kamyun، kamyunet و minibus است. برای تحلیل عمیق‌تر باید تصاویر خطادارِ واقعی همراه با برچسب صحیح، برچسب پیش‌بینی‌شده و امتیاز مدل ذخیره و بررسی شوند. گزارش حاضر بدون دسترسی به فهرست تصویری خطاها، نمونه‌ی ساختگی به‌عنوان خطای واقعی نمایش نمی‌دهد.

۱۲. بررسی اولیه‌ی مجموعه‌های ارائه‌شده توسط منتور

در ادامه‌ی پروژه، چند پوشه‌ی آزمون با نام‌های ۰، ۱، ۱۲، ۲، ۳ و ۴ بررسی شده‌اند. اعداد زیر همان نتایج اولیه‌ی ثبت‌شده‌اند و به دلیل وجود تکرار محتوایی و ناسازگاری برچسب‌ها، فعلاً نباید به‌عنوان معیار نهایی و مستقل عملکرد مدل ارائه شوند.

پوشه	تعداد رخداد تصویر	صحیح	اشتباه	دقت اولیه
۰	۹۵۸	۹۰۱	۵۷	۹۴٫۰۵٪
۱	۱۰۸۱	۱۰۲۱	۶۰	۹۴٫۴۵٪
۱۲	۱۰۸۱	۹۰۲	۱۷۹	۸۳٫۴۴٪
۲	۱۱۱۸	۱۰۵۳	۶۵	۹۴٫۱۹٪
۳	۱۱۱۸	۹۴۱	۱۷۷	۸۴٫۱۷٪
۴	۱۱۱۶	۹۲۷	۱۸۹	۸۳٫۰۶٪

۱۲.۱ چرا این اعداد موقت‌اند؟

ممیزی هش محتوا نشان داده است که ۶۴۷۲ رخداد تصویر در این پوشه‌ها به ۱۱۱۸ تصویر یکتا مربوط‌اند و برای ۲۶۴ محتوای یکتا، برچسب‌های ناسازگار دیده شده است. بنابراین ممکن است یک تصویر در چند پوشه تکرار شده باشد یا در پوشه‌های مختلف با برچسب‌های متفاوت ظاهر شود. تا زمانی که هر تصویر دقیقاً یک برچسب معتبر داشته باشد و پروتکل ارزیابی روشن شود، مقایسه‌ی این پوشه‌ها می‌تواند گمراه‌کننده باشد.

پیشنهاد برای نسخه‌ی نهایی: ابتدا یک فهرست شامل مسیر تصویر، هش محتوا، برچسب مرجع و منبع تصویر تهیه شود؛ سپس تکراری‌ها و اختلاف برچسب‌ها حل شوند و ارزیابی نهایی فقط روی داده‌ی تأییدشده انجام شود.

۱۳. بازتولیدپذیری و ساختار پروژه

ثبت ساختار فایل‌ها و تنظیمات آزمایش کمک می‌کند نتایج در آینده دوباره تولید و با نسخه‌های جدید مقایسه شوند. در پروژه، کدها به بخش‌های جداگانه برای مدل، آموزش، ارزیابی و آماده‌سازی داده تقسیم شده‌اند.

- تصاویر مورد استفاده برای آموزش.
- ۴۰۰ تصویر ارزیابی محلی در نسخه‌ی فعلی؛ نه آزمون نهایی منتور.
- وزن‌های آموزش‌دیده‌ی مدل ResNet18.
- تعریف معماری و خروجی هشت‌کلاسه.
- اجرای فرایند آموزش.
- ارزیابی مدل و محاسبه‌ی معیارها، در صورت وجود در نسخه‌ی جاری.
- ثبت آزمایش‌ها و نتایج.
- تصویر ماتریس درهم‌ریختگی، در صورت تولید و ذخیره.

۱۳.۱ مواردی که باید همراه نتیجه ثبت شوند

1. نسخه‌ی دیتاست و تعداد تصاویر هر کلاس.
2. نام دقیق مدل و روش استفاده از وزن‌ها.
3. Epoch، Batch Size، Learning Rate و Optimizer.
4. نوع Early Stopping، Dropout، Augmentation و Weight Decay، فقط اگر واقعاً استفاده شده باشند.
5. نسخه‌ی کتابخانه‌ها، دستگاه آموزش و مسیر خروجی‌ها.
6. تفکیک روشن Train، Validation و Test نهایی.

برای گزارش فعلی، هر پارامتری که در سابقه‌ی آزمایش ثبت نشده، به‌عنوان مقدار قطعی معرفی نشده است. این کار از نسبت دادن تنظیمات حدسی به آزمایش جلوگیری می‌کند.

۱۴. محدودیت‌ها و تهدیدهای اعتبار

۱۴.۱ محدودیت داده

تعداد تصاویر نسبت به مسائل بزرگ بینایی ماشین محدود است و برخی کلاس‌ها از نظر ظاهری هم‌پوشانی دارند. وجود تصاویر تکراری یا برچسب‌های ناسازگار می‌تواند ارزیابی را منحرف کند؛ بنابراین کیفیت برچسب‌ها به‌اندازه‌ی معماری مدل اهمیت دارد.

۱۴.۲ محدودیت ارزیابی

دقت ۹۵٫۷۵٪ مربوط به مجموعه‌ی ۴۰۰ تصویری ارزیابی محلی است. تا زمانی که مدل روی مجموعه‌ی آزمون نهاییِ مستقل و پاک‌سازی‌شده ارزیابی نشود، این عدد را نباید دقت نهایی روی داده‌های دیده‌نشده معرفی کرد.

۱۴.۳ محدودیت آزمایش‌ها

آزمایش کنترل بیش‌برازش در اجرای ثبت‌شده به دقت اعتبارسنجی پایین‌تری رسیده است. نمونه‌گیری وزن‌دار فقط از نظر توزیع نمونه‌ها بررسی شده و مقایسه‌ی تابع زیان نیز به یک بررسی اولیه‌ی تکBatch محدود بوده است. برای ادعای برتری این روش‌ها، آموزش و ارزیابی باید کامل و قابل مقایسه انجام شود.

۱۴.۴ محدودیت تعمیم

عملکرد مدل ممکن است با تغییر دوربین، زاویه، نور، کیفیت تصویر، پس‌زمینه یا توزیع خودروها تغییر کند. آزمون مستقل، بررسی نمونه‌های خارج از توزیع و تحلیل خطا برای سنجش کاربردپذیری واقعی ضروری‌اند.

۱۵. کارهای پیشنهادی برای ادامه‌ی پروژه

1. پاک‌سازی نهایی مجموعه‌ی منتور با استفاده از هش محتوا و رفع برچسب‌های متناقض.
2. جدا نگه‌داشتن کامل Train، Validation و Test نهایی و بررسی هم‌پوشانی میان آن‌ها.
3. ذخیره‌ی حداقل ۱۲ نمونه‌ی خطا همراه با تصویر، کلاس واقعی، کلاس پیش‌بینی‌شده و امتیاز مدل.
4. اجرای مقایسه‌ی کنترل‌شده‌ی مدل پایه و ResNet18 با تنظیمات و تقسیم‌ی داده یکسان.
5. بررسی جداگانه‌ی اثر Augmentation، Dropout و Early Stopping.
6. ثبت نمودارهای Loss و Accuracy برای هر مدل.
7. آزمایش ResNet18 در برابر تغییر روشنایی، برش، وضوح و پس‌زمینه.
8. ثبت خروجی پیش‌بینی‌ها در قالب CSV شامل نام فایل، کلاس واقعی، کلاس پیش‌بینی‌شده و امتیاز مدل.

نتیجه‌گیری

در این پروژه، یک مسیر عملی برای طبقه‌بندی هشت کلاس خودرویی از روی تصویر پیاده‌سازی شد. پس از ادغام و پاک‌سازی داده‌ها، یک مدل پایه به‌عنوان خط مبنا آموزش داده شد و سپس ResNet18 با استفاده از انتقال یادگیری مورد آزمایش قرار گرفت. در نتایج ثبت‌شده، ResNet18 به دقت آموزش ۹۸/۵۷٪ و دقت ارزیابی محلی ۹۵/۷۵٪ دست یافت و معیارهای Macro Precision، Macro Recall و Macro F1 همگی برابر ۰/۹۶ گزارش شدند.

تحلیل کلاس‌ها نشان داد که عملکرد کلی خوب است، اما تشخیص برخی گروه‌های مشابه مانند kamyun و kamyunet همچنان دشوارتر است. همچنین ممیزی پوشه‌های آزمون منتور وجود تکرار محتوا و اختلاف برچسب را نشان داد؛ بنابراین نتایج آن مجموعه‌ها تا زمان اصلاح داده‌ها موقت باقی می‌مانند. گام مهم بعدی، ایجاد یک پروتکل ارزیابی نهایی قابل اعتماد و سپس تحلیل سیستماتیک خطاهاست.

جمع‌بندی نهایی: ResNet18 بهترین مدل ثبت‌شده در مرحله‌ی ارزیابی محلی پروژه است؛ تأیید عملکرد نهایی منوط به ارزیابی روی Test مستقل و پاک‌سازی‌شده است.

پیوست: خلاصه‌ی نتایج ثبت‌شده

آزمایش	نتیجه‌ی کلیدی	وضعیت تفسیر
مدل پایه	آموزش ۹۸٫۵۲٪؛ اعتبارسنجی ۸۲٫۷۵٪	فاصله‌ی زیاد میان آموزش و اعتبارسنجی
کنترل بیش‌برازش	بهترین ۷۸٫۲۵٪ در Epoch ۸	در این اجرا بهتر نشد
نمونه‌گیری وزن‌دار	۷۲۵ نمونه در هر Epoch	فقط توزیع نمونه بررسی شد
مقایسه‌ی تابع زیان	۲٫۰۴۴۶۸ در برابر ۰٫۶۹۴۷۵ روی یک Batch	مستقیماً قابل مقایسه نیست
ResNet18	آموزش ۹۸٫۵۷٪؛ ارزیابی محلی ۹۵٫۷۵٪	بهترین نتیجه‌ی محلی ثبت‌شده

منبع نتایج: یادداشت‌ها و خروجی‌های ثبت‌شده‌ی پروژه. مقادیر فاقد سابقه‌ی قطعی، به‌صورت حدس وارد نشده‌اند.